

MCDI504

MACHINE LEARNING I

**AVANCE DEL PROYECTO — FASE 1:
DEFINICIÓN Y ORIENTACIÓN DE LA
SITUACIÓN**

Nombres integrantes:

Jennifer Nilo

Patricio Núñez

Curso:

MCDI504 – Machine Learning I

Fecha: 09-08-2026

Grupo: 8

I. Índice

Contenido

I.	Índice	2
II.	Introducción y contextualización.....	3
III.	Definición de la problemática y objetivos del proyecto.....	4
IV.	Clasificación del tipo de aprendizaje	6
V.	Relación entre Machine Learning y metodología KDD	7
VI.	Notebook F1_Definicion.ipynb.....	8
VII.	Comparación de enfoques	12
VIII.	Documentación del proceso	13
IX.	Conclusiones	15
X.	Uso de fuentes, citación y referencias.....	16
XI.	Anexos	17

II. Introducción y contextualización

El presente informe corresponde al Avance del Proyecto - Fase 1: Definición y orientación de la situación de la asignatura MCDI504 - Machine Learning I. En esta etapa el propósito es definir el problema analítico, comprender los datos disponibles, seleccionar el tipo de aprendizaje y relacionar el trabajo con la metodología KDD. De acuerdo con las instrucciones de la actividad, en esta fase no se desarrolla modelamiento, sino que se establece la base conceptual y metodológica para las fases siguientes (Universidad Andrés Bello, 2026).

El caso de análisis corresponde al dataset Iris, cargado desde `sklearn.datasets`. El conjunto contiene mediciones morfológicas de flores pertenecientes a tres especies: setosa, versicolor y virginica. Para cada observación se registran cuatro variables numéricas continuas: `Sepal.Length`, `Sepal.Width`, `Petal.Length` y `Petal.Width`, además de la variable categórica `Species`. En la ejecución del notebook se obtuvieron 150 observaciones y 5 columnas.

La situación analítica consiste en evaluar si estas mediciones contienen información suficiente para diferenciar las especies. Como cada registro posee variables de entrada y una etiqueta conocida, el problema puede formularse como aprendizaje supervisado de clasificación multiclase. Esta clasificación es coherente con la definición general de aprendizaje supervisado revisada en el material del curso (Ruete, 2026) y con la forma en que `scikit-learn` representa el dataset Iris (Scikit-learn developers, s. f.).

Elemento	Descripción aplicada al proyecto
Contexto del caso	Análisis académico del dataset Iris para estudiar la clasificación de tres especies mediante variables morfológicas.
Situación que origina el análisis	Determinar si las mediciones de sépalos y pétalos permiten diferenciar setosa, versicolor y virginica.
Datos disponibles	Dataset Iris con 150 observaciones; cuatro variables numéricas continuas y una variable categórica <code>Species</code> .
Objetivo analítico	Formalizar un problema de clasificación supervisada y dejar preparada la base técnica para fases posteriores.
Tipo de aprendizaje esperado	Aprendizaje supervisado de clasificación multiclase.

III. Definición de la problemática y objetivos del proyecto

3.1 Formulación del problema

Se requiere analizar las características morfológicas registradas en el dataset Iris y evaluar su congruencia para construir, en fases posteriores, un sistema capaz de clasificar una flor en una de tres especies conocidas. El problema se aborda desde ciencia de datos porque existen variables predictoras cuantitativas y una variable objetivo categórica que puede utilizarse como etiqueta.

En esta Fase 1 no se entrena ningún algoritmo. El trabajo se concentra en revisar la estructura y calidad de los datos, explorar sus características principales, justificar el tipo de aprendizaje y documentar las decisiones que permitirán continuar posteriormente con entrenamiento y evaluación.

3.2 Pregunta analítica

¿Es posible identificar la especie de una flor Iris a partir del largo y ancho de sus sépalos y pétalos?

3.3 Objetivo general

Definir y fundamentar un problema de clasificación supervisada orientado a identificar la especie de una flor Iris mediante sus características morfológicas, verificando previamente la estructura, calidad y utilidad inicial de los datos.

3.4 Objetivos específicos

1. Cargar y describir la estructura del dataset Iris.
2. Identificar las variables predictoras y la variable objetivo.
3. Verificar tipos de datos, valores nulos, duplicados y distribución de clases.
4. Explorar estadísticamente las variables numéricas y sus relaciones.
5. Justificar el aprendizaje supervisado como enfoque metodológico.
6. Relacionar las actividades realizadas con las etapas de KDD.
7. Documentar las decisiones técnicas que orientarán las fases posteriores.

3.5 Tipo de datos considerados y alcance

Aspecto	Definición en el proyecto
Unidad de análisis	Cada observación corresponde a una flor Iris.
Variables predictoras	Sepal.Length, Sepal.Width, Petal.Length y Petal.Width; variables numéricas continuas.
Variable objetivo	Species; variable categórica nominal con tres clases: setosa, versicolor y virginica.
Cantidad de observaciones	150 registros.
Calidad inicial	0 valores nulos; 1 duplicado exacto documentado y conservado.
Balance de clases	50 observaciones por especie, equivalentes al 33,33 % cada una.
Alcance	Definición, selección, preprocesamiento, transformación exploratoria e interpretación inicial. No incluye entrenamiento ni evaluación de modelos.

3.6 Relación entre el problema definido y KDD

La metodología KDD permite organizar el trabajo desde la selección de datos hasta su interpretación. En este proyecto se selecciona el dataset Iris, se revisan tipos de datos, nulos, duplicados y posibles valores atípicos, se realizan transformaciones exploratorias y se interpretan los resultados obtenidos. La minería de datos mediante modelos de Machine Learning queda proyectada para las fases posteriores. Esta relación es coherente con la idea de KDD como un proceso más amplio que la aplicación aislada de un algoritmo (Fayyad et al., 1996).

IV. Clasificación del tipo de aprendizaje

El tipo de aprendizaje seleccionado es aprendizaje supervisado, específicamente una tarea de clasificación multiclase. La decisión se basa en que cada observación posee una etiqueta conocida en Species y el resultado esperado corresponde a una categoría discreta, no a una magnitud numérica continua.

Criterio	Evidencia obtenida	Decisión
Variable objetivo	Species está disponible para las 150 observaciones.	Aprendizaje supervisado.
Tipo de objetivo	Species es categórica nominal con tres clases.	Clasificación multiclase.
Variables de entrada	Cuatro mediciones numéricas continuas.	Uso de predictores cuantitativos.
Propósito	Asignar una de tres especies a partir de las mediciones.	Predicción de clase.
Condición inicial	Clases balanceadas y sin valores nulos.	Base adecuada para continuar a fases posteriores.

No se selecciona aprendizaje no supervisado como enfoque principal porque el dataset ya contiene etiquetas conocidas y el objetivo no es descubrir grupos desconocidos. Tampoco corresponde aprendizaje por refuerzo, ya que no existe un agente que tome acciones y reciba recompensas. La regresión también se descarta para el objetivo central, porque Species no es una variable continua (Ruete, 2026).

V. Relación entre Machine Learning y metodología KDD

El Machine Learning se considera una parte del proceso KDD y no el proceso completo. Antes de entrenar un modelo es necesario seleccionar datos, revisar su calidad y preparar las variables. Después del modelamiento también será necesario interpretar los resultados y verificar si responden la pregunta analítica.

Relación entre el proyecto y las etapas de KDD



Figura 1. Diagrama del flujo KDD utilizado en la Fase 1.

Etapa KDD	Función en el proyecto	Evidencia del notebook
Selección	Elegir el dataset Iris y distinguir variables predictoras y objetivo.	Carga con <code>load_iris()</code> , DataFrame de 150 filas y 5 columnas.
Preprocesamiento	Revisar tipos, nulos, duplicados, consistencia y posibles atípicos.	Revisión de estructura, nulos, duplicados y boxplots.
Transformación	Preparar variables para análisis y fases posteriores.	Codificación temporal de Species y normalización Min-Max exploratoria.
Minería de datos / ML	Entrenar algoritmos de clasificación supervisada.	No se implementa en Fase 1; queda proyectado.
Interpretación	Relacionar resultados con la pregunta analítica.	Lectura de estadísticas, correlaciones y p-valores.

El flujo utilizado cumple el indicador de relacionar Machine Learning y KDD, porque cada etapa tiene una función concreta dentro del proyecto. En esta fase, la mayor parte de la evidencia se concentra en selección, preprocesamiento, transformación e interpretación inicial.

VI. Notebook F1_Definicion.ipynb

El notebook **F1_Definicion.ipynb** constituye la evidencia computacional del trabajo. Su estructura mantiene correspondencia con el problema, los objetivos y el enfoque seleccionado. El archivo se encuentra versionado en el siguiente repositorio:

<https://github.com/pnunezcarreno/machinelearning1>, en la ruta /notebooks/F1_Definicion.ipynb.

6.1 Estructura del flujo técnico

Bloque	Propósito	Evidencia obtenida
Contexto y problema	Definir pregunta, objetivos y alcance.	Problema de clasificación multiclase formalizado.
Configuración	Importar librerías y registrar versiones.	Python 3.12.13; pandas 2.2.2; NumPy 2.0.2; scikit-learn 1.6.1.
Selección y carga	Construir df_iris desde load_iris().	150 filas y 5 columnas.
Preprocesamiento	Revisar estructura, nulos, duplicados y balance.	0 nulos; 1 duplicado exacto; 50 registros por especie.
Exploración	Calcular estadísticas y revisar distribuciones.	Resumen descriptivo y boxplots por especie.
Correlación	Explorar relaciones lineales.	Matriz de Pearson con Species codificada.
Significancia	Complementar Pearson con p-valores.	Matriz de p-valores con $\alpha = 0,05$.
Normalización	Mostrar escalamiento preliminar.	Variables predictoras en intervalo [0,1].
Síntesis	Documentar decisiones y proyección.	Conclusiones y continuidad hacia Fases 2-4.

6.2 Código base representativo

A continuación se presentan fragmentos representativos del código utilizado. El notebook completo contiene las salidas y comentarios que permiten verificar cada decisión.

```
iris = load_iris()
columnas = [
    "Sepal.Length",
    "Sepal.Width",
    "Petal.Length",
    "Petal.Width"
]

df_iris = pd.DataFrame(iris.data, columns=columnas)
df_iris["Species"] = pd.Categorical.from_codes(
    iris.target,
    categories=iris.target_names
)
```

```
mapa_species = {"setosa": 1, "versicolor": 2, "virginica": 3}
df_iris_codificado = df_iris.copy()
df_iris_codificado["Species"] = (
    df_iris_codificado["Species"].astype(str).map(mapa_species).astype(int)
)
matriz_correlacion = df_iris_codificado.corr(method="pearson")
```

```
matriz_pvalores = calcular_pvalores(
    df_iris_codificado[
        ["Sepal.Length", "Sepal.Width", "Petal.Length", "Petal.Width", "Species"]
    ]
)
```



```

scaler_exploratorio = MinMaxScaler()
df_normalizado = pd.DataFrame(
    scaler_exploratorio.fit_transform(df_iris[columnas]),
    columns=columnas,
    index=df_iris.index
)

```

6.3 Resultados técnicos obtenidos

La ejecución confirma que el dataset contiene 150 observaciones, cuatro variables predictoras numéricas continuas y una variable objetivo categórica. La revisión de calidad no encontró valores nulos. Se detectó un duplicado exacto: las observaciones 101 y 142 poseen las mismas mediciones y corresponden a virginica; se decidió conservarlas porque la igualdad de mediciones no demuestra por sí sola un error.

Variable	Media	Desv. estándar	Mínimo	Mediana	Máximo
Sepal.Length	5,843	0,828	4,300	5,800	7,900
Sepal.Width	3,057	0,436	2,000	3,000	4,400
Petal.Length	3,758	1,765	1,000	4,350	6,900
Petal.Width	1,199	0,762	0,100	1,300	2,500

Las variables presentan escalas y niveles de dispersión diferentes. De acuerdo con la estadística descriptiva, Petal.Length presenta valores entre 1,0 y 6,9, mientras que Sepal.Length presenta valores entre 4,3 y 7,9. Estas diferencias de escala respaldan la incorporación de la normalización Min-Max como una transformación preliminar para algoritmos que puedan ser sensibles a la escala.




Figura 2. Distribución de la variable objetivo Species.

La distribución de Species es equilibrada: setosa, versicolor y virginica presentan 50 observaciones cada una, equivalentes al 33,33 % del dataset. En esta revisión inicial no se observa desbalance de clases.




Figura 3. Distribución y posibles valores atípicos de las variables morfológicas según especie.

Los boxplots permiten comparar las variables por especie y reconocer observaciones extremas. En esta fase no se eliminan posibles atípicos, porque pueden representar variabilidad real de las mediciones y no necesariamente errores.




Figura 4. Matriz de correlación de Pearson con Species codificada.

La matriz de Pearson muestra una relación positiva muy fuerte entre Petal.Length y Petal.Width ($r \approx 0,963$). También se observan asociaciones altas entre Species codificada y Petal.Length ($r \approx 0,949$) y Petal.Width ($r \approx 0,957$). Estas últimas se interpretan con precaución porque Species sigue siendo una variable categórica nominal y la codificación 1, 2 y 3 se utiliza solamente como apoyo exploratorio.




Figura 5. Matriz de p-valores para las correlaciones de Pearson.

Los p-valores se analizan usando un nivel de significancia de 0,05. La relación entre Sepal.Length y Sepal.Width presenta $p \approx 0,1519$, por lo que no existe evidencia suficiente para considerarla una relación lineal significativa. Los valores mostrados como 0,0000 en la matriz corresponden a valores muy pequeños por efecto del redondeo y no deben interpretarse como un valor exactamente igual a cero.

La normalización Min-Max dejó las cuatro variables predictoras en el intervalo $[0,1]$. Esta transformación se mantiene como exploratoria: su utilización definitiva dependerá del algoritmo que se seleccione en fases posteriores.

VII. Comparación de enfoques

La selección del aprendizaje supervisado se contrastó con otras alternativas para comprobar que el enfoque elegido responde al tipo de datos y al objetivo del proyecto.

Enfoque	Señal o dato asociado	Uso típico	Evaluación para Iris
Supervisado	Variables de entrada y etiquetas conocidas.	Clasificación o regresión.	Seleccionado: existen mediciones y Species conocida por registro.
No supervisado	Variables sin etiqueta objetivo.	Agrupamiento o reducción de dimensionalidad.	Descartado como enfoque principal; podría usarse de forma complementaria.
Por refuerzo	Estados, acciones y recompensas.	Decisiones secuenciales.	Descartado: no existe agente, acción ni recompensa.

Además, dentro del aprendizaje supervisado, la regresión no corresponde al objetivo central porque la variable que se desea predecir es categórica. Por lo tanto, la clasificación multiclase es la alternativa que presenta mayor coherencia entre problema, datos y propósito analítico.

VIII. Documentación del proceso

La documentación del proceso registra las principales decisiones adoptadas y permite verificar su correspondencia con las salidas del notebook. Este registro facilita la trazabilidad entre informe, notebook y repositorio.

Decisión técnica	Justificación	Evidencia
Usar el dataset Iris	Contiene cuatro predictores numéricos y una etiqueta con tres clases.	Carga con <code>load_iris()</code> y diccionario de variables.
Definir Species como objetivo	La pregunta analítica busca identificar la especie.	Species aparece como variable objetivo en el notebook.
Seleccionar clasificación supervisada	Cada registro posee una etiqueta conocida.	Sección de clasificación del aprendizaje.
Conservar el duplicado	Dos flores pueden compartir las mismas mediciones; no existe evidencia de error.	1 duplicado exacto documentado: índices 101 y 142.
No imputar nulos	No se detectaron valores faltantes.	0 nulos en las cinco variables.
Conservar posibles atípicos	El boxplot no demuestra que sean errores.	Boxplots por especie e interpretación.
Codificar Species 1-2-3	Permite reproducir el análisis de Pearson con la etiqueta.	<code>df_iris_codificado</code> y mapa de categorías.
Interpretar Species con precaución	Sigue siendo una categoría nominal.	Nota metodológica posterior a Pearson.
Calcular p-valores	Complementan la fuerza de correlación con significancia.	Matriz de p-valores, $\alpha = 0,05$.
Normalizar de forma exploratoria	Puede ser útil para algoritmos sensibles a escala.	<code>df_normalizado</code> con mínimos 0 y máximos 1.
No modelar en Fase 1	La actividad solicita fundamentar el enfoque antes de entrenar modelos.	No existen celdas de entrenamiento ni evaluación.
Documentar narrativa y código en el notebook.	Favorece reproducibilidad, comprensión y trazabilidad del flujo analítico.	Repositorio: <code>/notebook/F1_Definicion.ipynb</code> .

8.1 Cambios realizados durante el desarrollo

- Se incorporó la definición analítica del problema y la pregunta de análisis.
- Se agregaron el objetivo general y los objetivos específicos.
- Se identificaron formalmente las variables predictoras y la variable objetivo.
- Se explicitó la selección del aprendizaje supervisado de clasificación multiclase.
- Se organizó el flujo de trabajo de acuerdo con las etapas de KDD.
- Se incorporó la revisión de valores nulos, registros duplicados y distribución de clases.
- Se agregaron interpretaciones después de las principales salidas del código.
- Se aplicó la codificación de Species como 1, 2 y 3 para el análisis de correlación.
- Se incorporó el análisis de p-valores como complemento de Pearson.
- La normalización Min-Max se mantuvo como transformación preliminar y no como decisión definitiva.

8.2 Correspondencia entre los componentes del Proyecto

Componente	Ubicación / evidencia
Informe	MCDI504_S1_1_GRUPO8 - Fase 1.
Notebook	F1_Definicion.ipynb / versión ejecutada utilizada como evidencia.
Repositorio	https://github.com/pnunezcarreno/machinelearning1
Ruta en repositorio	/notebook/F1_Definicion.ipynb
Dataset	Iris, cargado desde sklearn.datasets.

IX. Conclusiones

El desarrollo de la Fase 1 permitió formular el análisis del dataset Iris como un problema de ciencia de datos. La pregunta analítica busca establecer si las mediciones del sépalo y del pétalo permiten diferenciar la especie de una flor.

A partir de la estructura observada se seleccionó aprendizaje supervisado de clasificación multiclase. La decisión se fundamenta en que las cuatro variables predictoras son numéricas y cada registro posee una etiqueta conocida en Species, compuesta por setosa, versicolor y virginica.

La exploración confirmó 150 observaciones, 0 valores nulos y una distribución equilibrada de 50 observaciones por especie. Se detectó 1 duplicado exacto, correspondiente a dos registros de virginica con las mismas mediciones; se decidió conservarlo porque la coincidencia de valores no constituye evidencia suficiente de un error.

En el análisis de relaciones, Petal.Length y Petal.Width presentan una correlación positiva muy fuerte ($r \approx 0,96$). En cambio, Sepal.Length y Sepal.Width presentan una relación débil ($r \approx -0,12$) y su p-valor aproximado de 0,152 no entrega evidencia suficiente de relación lineal significativa con $\alpha = 0,05$. Las correlaciones que incluyen Species codificada se consideran solo exploratorias, ya que la variable mantiene su naturaleza categórica nominal.

La normalización Min-Max se evaluó como preparación preliminar y dejó las variables predictoras en $[0,1]$, pero su aplicación final dependerá del algoritmo seleccionado. En relación con KDD, la fase desarrolló selección, preprocesamiento, transformación e interpretación inicial, mientras que el modelamiento queda reservado para las fases siguientes.

Como proyección, el proyecto podrá continuar con separación de datos de entrenamiento y prueba, evaluación de algoritmos de clasificación, comparación de métricas y selección del modelo con mejor desempeño y capacidad de generalización. De esta forma, las decisiones adoptadas en Fase 1 dejan una base coherente entre problema, datos, tipo de aprendizaje y proceso KDD.

X. Uso de fuentes, citación y referencias

El informe utiliza material docente para sustentar la definición de los tipos de aprendizaje y los requerimientos de la Fase 1, documentación técnica oficial para respaldar el uso de pandas y scikit-learn, y fuentes académicas para relacionar el trabajo con KDD y con el uso de scikit-learn en Machine Learning. Las referencias se presentan en formato APA y corresponden a las fuentes utilizadas en el notebook.

- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37-54.
- pandas development team. (s. f.). *pandas documentation*. <https://pandas.pydata.org/docs/>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Ruete, D. (2026). *Introducción al Machine Learning* [Apunte]. Universidad Andrés Bello.
- Scikit-learn developers. (s. f.). *The Iris dataset*. Documentación de scikit-learn. https://scikit-learn.org/stable/auto_examples/decomposition/plot_pca_iris.html
- Universidad Andrés Bello. (2026). *MCDI504 Machine Learning I: Avance del proyecto - Fase 1, definición y orientación de la situación* [Material docente].

XI. Anexos

Anexo A. Diccionario de variables

Variable	Descripción	Tipo conceptual	Rol analítico
Sepal.Length	Longitud del sépalo	Numérica continua	Predictora
Sepal.Width	Ancho del sépalo	Numérica continua	Predictora
Petal.Length	Longitud del pétalo	Numérica continua	Predictora
Petal.Width	Ancho del pétalo	Numérica continua	Predictora
Species	Especie de la flor	Catégorica nominal	Objetivo

Anexo B. Evidencia de calidad de datos

Variable	Tipo	No nulos	Nulos	Valores únicos
Sepal.Length	float64	150	0	35
Sepal.Width	float64	150	0	23
Petal.Length	float64	150	0	43
Petal.Width	float64	150	0	22
Species	category	150	0	3

Duplicado exacto detectado: las filas 101 y 142 presentan Sepal.Length = 5,8; Sepal.Width = 2,7; Petal.Length = 5,1; Petal.Width = 1,9; Species = virginica. El registro se documentó y se conservó.

Anexo C. Distribución de clases

Species	Cantidad	Porcentaje
setosa	50	33,33 %
versicolor	50	33,33 %
virginica	50	33,33 %

Anexo D. Matriz de correlación de Pearson

Variable	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
Sepal.Length	1,000	-0,118	0,872	0,818	0,783
Sepal.Width	-0,118	1,000	-0,428	-0,366	-0,427
Petal.Length	0,872	-0,428	1,000	0,963	0,949
Petal.Width	0,818	-0,366	0,963	1,000	0,957
Species	0,783	-0,427	0,949	0,957	1,000

Nota: Species fue codificada como setosa = 1, versicolor = 2 y virginica = 3 solo para reproducir el análisis exploratorio de Pearson. La variable sigue siendo catégorica nominal.