

MCDI504

MACHINE LEARNING I

**AVANCE DEL PROYECTO — FASE 2:
IMPLEMENTACIÓN DE MODELOS DE
REGRESIÓN SUPERVISADA**

Nombres integrantes:

Jennifer Nilo, Patricio Núñez

Curso:

MCDI504 - Machine learning I

Fecha:

16-08-2026

Grupo: GRUPO8

I. Índice

Contenido

I.	Índice	2
II.	Introducción y contextualización.....	3
III.	Descripción del conjunto de datos y preprocesamiento.....	4
3.1	Descripción general del dataset	4
3.2	Valores faltantes y selección de variables	4
3.3	Partición y escalamiento.....	4
IV.	Modelo de regresión lineal simple	5
4.1	Variables y evidencia de ejecución.....	5
4.2	Interpretación inicial	5
V.	Modelo de árboles de decisión para regresión	6
5.1	Configuración mínima y ejecución	6
5.2	Interpretación del comportamiento	6
VI.	Modelo de redes neuronales para regresión	7
6.1	Configuración mínima y ejecución	7
6.2	Interpretación del comportamiento	7
VII.	Evaluación de modelos de regresión.....	8
VIII.	Comparación de modelos	9
8.1	Elección analítica	9
IX.	Notebook F2_Regresion.ipynb y documentación del proceso	10
X.	Conclusiones	11
XI.	Uso de fuentes, citación y referencias.....	12
XII.	Anexos	13

II. Introducción y contextualización

Este informe presenta el trabajo realizado en la Fase 2 con el dataset California Housing. El problema corresponde a regresión supervisada, ya que la variable que se busca predecir, MedHouseVal, es continua. El objetivo es implementar y comparar una regresión lineal simple, un árbol de decisión y una red neuronal MLP (Ruede, 2026b, Ruede, 2026e).

La situación de análisis consiste en estimar el valor mediano de las viviendas usando la información disponible en el dataset. Para la regresión lineal simple se utiliza la variable MedInc como único predictor. Para el árbol de decisión y la red neuronal se utilizan las ocho variables predictoras disponibles.

Los tres modelos se evalúan con MSE, RMSE y R^2 sobre un conjunto de prueba. Estas métricas permiten comparar el error de predicción y la proporción de variabilidad explicada por cada modelo (Ruede, 2026a).

Elemento	Descripción aplicada al caso
Contexto del caso	El análisis se desarrolla sobre el dataset California Housing, cuyo propósito es predecir el valor mediano de las viviendas de distritos censales de California a partir de información socioeconómica, habitacional y geográfica.
Situación que origina el análisis	Se busca estimar una variable continua, MedHouseVal, utilizando modelos de regresión supervisada y comparar su desempeño sobre datos de prueba.
Datos disponibles	El dataset contiene 20.640 observaciones, ocho variables predictoras y una variable objetivo continua. Para la regresión lineal simple se utiliza la variable MedInc como único predictor, mientras que el árbol de decisión y la red neuronal MLP utilizan las ocho variables disponibles.
Objetivo analítico	Implementar y comparar una regresión lineal simple, un árbol de decisión y una red neuronal MLP mediante las métricas MSE, RMSE y R^2 , con el fin de identificar el modelo con mejor desempeño predictivo en esta ejecución.
Tipo de aprendizaje	Aprendizaje supervisado de regresión, ya que los modelos se entrenan utilizando una variable objetivo conocida y continua, correspondiente a MedHouseVal.
Variable objetivo	MedHouseVal, que representa el valor mediano de las viviendas y constituye la variable continua que se desea predecir.
Variables predictoras	MedInc, HouseAge, AveRooms, AveBedrms, Population, AveOccup, Latitude y Longitude. En el modelo lineal simple se utiliza únicamente MedInc.
Criterio de evaluación	Los modelos se comparan mediante MSE, RMSE y R^2 calculados sobre el conjunto de prueba. Un menor MSE y RMSE representa menor error, mientras que un mayor R^2 indica una mayor proporción de variabilidad explicada.

III. Descripción del conjunto de datos y preprocesamiento

3.1 Descripción general del dataset

California Housing contiene 20.640 registros. En el notebook se cargan ocho variables predictoras y la variable objetivo MedHouseVal. La revisión inicial muestra que el dataset no presenta valores faltantes.

Variable	Rol	Descripción
MedInc	Predictora	Ingreso mediano del distrito.
HouseAge	Predictora	Edad media de las viviendas.
AveRooms	Predictora	Número medio de habitaciones.
AveBedrms	Predictora	Número medio de dormitorios.
Population	Predictora	Población del distrito.
AveOccup	Predictora	Número medio de ocupantes por hogar.
Latitude	Predictora	Latitud.
Longitude	Predictora	Longitud.
MedHouseVal	Objetivo	Valor mediano de las viviendas.

3.2 Valores faltantes y selección de variables

El recuento de valores nulos es cero en todas las columnas, por lo que no se aplica eliminación ni imputación. Para cumplir con la regresión lineal simple se selecciona la variable MedInc como único predictor. Para el árbol y la MLP se mantienen las ocho variables predictoras.

3.3 Partición y escalamiento

La partición se realiza con 80% de los registros para entrenamiento y 20% para prueba, utilizando semilla 42 para reproducibilidad. El resultado es de 16.512 registros de entrenamiento y 4.128 de prueba.

Para la red neuronal se aplica StandardScaler. El escalador se ajusta con los datos de entrenamiento y luego se utiliza para transformar entrenamiento y prueba.

Conjunto	Registros
Entrenamiento	16512
Prueba	4128

IV. Modelo de regresión lineal simple

La regresión lineal simple se implementa con `LinearRegression` y utiliza únicamente la variable `MedInc` para predecir `MedHouseVal`, de acuerdo con la definición de un modelo lineal simple con una variable independiente (Rue, 2026e).

4.1 Variables y evidencia de ejecución

```
linear_model = LinearRegression()
linear_model.fit(X_train_simple, y_train)
y_pred_linear = linear_model.predict(X_test_simple)
```

Resultado	Valor
Intercepto	0,4446
Coefficiente <code>MedInc</code>	0,4193
MSE	0,7091
RMSE	0,8421
R^2	0,4589

4.2 Interpretación inicial

La regresión lineal simple obtuvo un R^2 de 0,4589, lo que indica que `MedInc`, utilizado como único predictor, explica aproximadamente un 45,89 % de la variabilidad observada en `MedHouseVal` dentro del conjunto de prueba. Este resultado muestra que el ingreso mediano del distrito aporta información relevante para estimar el valor mediano de las viviendas, aunque por sí solo no logra explicar la totalidad de las diferencias presentes en la variable objetivo.

Por otra parte, el modelo obtuvo un RMSE de 0,8421, valor que representa el error típico de las predicciones respecto de los valores reales de `MedHouseVal`. En comparación con los otros modelos evaluados, la regresión lineal simple presenta un desempeño más limitado, pero resulta útil como modelo base por su simplicidad y facilidad de interpretación, permitiendo establecer un punto de referencia para evaluar posteriormente el árbol de decisión y la red neuronal MLP.

V. Modelo de árboles de decisión para regresión

El árbol de decisión se utiliza para representar relaciones no lineales mediante divisiones sucesivas del espacio de variables (Ruede, 2026c). En el notebook se usan las ocho variables predictoras.

5.1 Configuración mínima y ejecución

Hiperparámetro	Valor
max_depth	5
random_state	42

```
decision_tree_model = DecisionTreeRegressor(max_depth=5, random_state=SEMILLA)
decision_tree_model.fit(X_train_full, y_train)
y_pred_tree = decision_tree_model.predict(X_test_full)
```

Métrica	Valor
MSE	0,5245
RMSE	0,7242
R ²	0,5997

5.2 Interpretación del comportamiento

El árbol de decisión obtuvo un MSE de 0,5245, un RMSE de 0,7242 y un R² de 0,5997, mostrando un mejor desempeño que la regresión lineal simple en las tres métricas evaluadas. La disminución del MSE y del RMSE indica que sus predicciones se encuentran más próximas a los valores reales de MedHouseVal, mientras que el R² señala que el modelo logra explicar aproximadamente un 59,97% de la variabilidad observada en la variable objetivo.

Esta mejora puede relacionarse con que el árbol utiliza las ocho variables predictoras disponibles y puede representar relaciones no lineales mediante divisiones sucesivas del espacio de datos. A diferencia de la regresión lineal simple, que utiliza únicamente MedInc, el árbol incorpora más información para realizar sus predicciones. Aun así, su desempeño es inferior al obtenido por la red neuronal MLP, por lo que se posiciona como un modelo intermedio entre la simplicidad del modelo lineal y la mayor capacidad predictiva de la red neuronal.

VI. Modelo de redes neuronales para regresión

La red neuronal se implementa mediante MLPRegressor. Este tipo de modelo puede representar relaciones no lineales y requiere considerar la escala de las variables de entrada (Ruede, 2026d).

6.1 Configuración mínima y ejecución

Hiperparámetro	Valor
hidden_layer_sizes	-100
activation	relu
solver	adam
max_iter	500
early_stopping	True
random_state	42

```
mlp_model = MLPRegressor(hidden_layer_sizes=(100,), activation="relu",
solver="adam", max_iter=500, random_state=SEMILLA, early_stopping=True)
mlp_model.fit(X_train_full_scaled, y_train)
y_pred_mlp = mlp_model.predict(X_test_full_scaled)
```

Métrica	Valor
MSE	0,3017
RMSE	0,5493
R ²	0,7697

6.2 Interpretación del comportamiento

La red neuronal MLP obtuvo un MSE de 0,3017, un RMSE de 0,5493 y un R² de 0,7697, alcanzando el mejor desempeño entre los tres modelos evaluados. El menor MSE y RMSE indican que sus predicciones presentan un error más bajo respecto de los valores reales de MedHouseVal, mientras que el R² muestra que el modelo logra explicar aproximadamente un 76,97 % de la variabilidad observada en la variable objetivo dentro del conjunto de prueba.

Este resultado muestra que la red neuronal fue capaz de aprovechar de mejor manera la información entregada por las ocho variables predictoras utilizadas en el entrenamiento. Su capacidad para representar relaciones no lineales permite obtener un mejor ajuste que la regresión lineal simple y el árbol de decisión. Sin embargo, este mejor desempeño también se acompaña de una menor interpretabilidad, ya que la red neuronal no permite explicar sus predicciones de forma tan directa como los otros modelos.

VII. Evaluación de modelos de regresión

Los modelos se evaluaron mediante MSE, RMSE y R^2 . En MSE y RMSE, valores menores representan menor error. En R^2 , un valor mayor representa una mayor proporción de variabilidad explicada (Ruete, 2026a, Ruete, 2026e).

Modelo	MSE	RMSE	R^2
Regresión Lineal Simple	0,7091	0,8421	0,4589
Árbol de Decisión	0,5245	0,7242	0,5997
Red Neuronal MLP	0,3017	0,5493	0,7697




Figura 1. Comparación de MSE, RMSE y R^2 entre los modelos.

La tabla y la figura muestran que la red neuronal presenta los mejores valores de las tres métricas. El árbol queda en una posición intermedia y la regresión lineal simple presenta el mayor error.

VIII. Comparación de modelos

Modelo	Fortalezas	Limitaciones
Regresión lineal simple	Alta interpretabilidad y simplicidad.	Solo utiliza MedInc y representa una relación lineal.
Árbol de decisión	Captura relaciones no lineales y utiliza múltiples predictores.	Puede sobreajustar si aumenta demasiado su complejidad.
Red neuronal MLP	Puede modelar relaciones no lineales complejas.	Menor interpretabilidad y mayor dependencia de hiperparámetros.

8.1 Elección analítica

La elección preliminar corresponde a la Red Neuronal MLP, ya que obtuvo el mejor desempeño entre los tres modelos evaluados, con un MSE de 0,3017, un RMSE de 0,5493 y un R^2 de 0,7697. En términos predictivos, este resultado indica que el modelo explica aproximadamente un 76,97 % de la variabilidad observada en MedHouseVal dentro del conjunto de prueba, además de presentar el menor error de predicción entre las alternativas implementadas.

Sin embargo, esta elección debe interpretarse considerando que la regresión lineal simple utiliza únicamente MedInc como predictor, mientras que el árbol de decisión y la red neuronal trabajan con las ocho variables disponibles. Por lo tanto, las diferencias observadas responden tanto al tipo de algoritmo como a la cantidad de información utilizada por cada modelo. Para mantener una comparación útil dentro del proyecto, la regresión lineal puede conservarse como referencia simple e interpretable, mientras que el árbol de decisión funciona como un punto intermedio de contraste frente al mayor desempeño alcanzado por la red neuronal.

IX. Notebook F2_Regresion.ipynb y documentación del proceso

El notebook contiene el flujo utilizado para obtener los resultados presentados en este informe, carga del dataset, revisión de valores faltantes, selección de variables, partición entrenamiento/prueba, escalamiento de la MLP, entrenamiento de los tres modelos, cálculo de métricas y comparación.

Apartado del informe	Sección del notebook
Descripción y preprocesamiento	II
Regresión lineal simple	III
Árbol de decisión	IV
Red neuronal MLP	V
Evaluación	VI
Comparación	VII
Conclusiones	IX

Repositorio: <https://github.com/pnunezcarreno/machinelearning1>

Ruta: notebook/F2_Regresion.ipynb

X. Conclusiones

En la fase 2 se logró implementar y evaluar los tres modelos de regresión solicitados sobre el dataset California Housing, utilizando un flujo de trabajo que incluyó la preparación de los datos, la separación entre entrenamiento y prueba, el uso de una semilla para asegurar reproducibilidad y el cálculo de las métricas MSE, RMSE y R^2 . Esto permitió comparar los modelos a partir de resultados obtenidos sobre datos no utilizados durante el entrenamiento.

La regresión lineal simple utilizó la variable MedInc como único predictor y obtuvo un MSE de 0,7091, un RMSE de 0,8421 y un R^2 de 0,4589. Estos resultados muestran que, utilizando solamente el ingreso mediano del distrito, el modelo logra explicar aproximadamente un 45,89 % de la variabilidad de MedHouseVal. Si bien este desempeño es menor al de los otros modelos, la regresión lineal simple cumple un rol importante como modelo base, ya que permite observar de manera directa la relación entre una variable predictora y la variable objetivo.

El árbol de decisión utilizó las ocho variables predictoras disponibles y presentó una mejora en las métricas, alcanzando un MSE de 0,5245, un RMSE de 0,7242 y un R^2 de 0,5997. Esto indica que el modelo logra reducir el error de predicción y explicar una mayor proporción de la variabilidad de MedHouseVal en comparación con la regresión lineal simple. Su mejor desempeño puede relacionarse con su capacidad de trabajar con varias variables y representar relaciones no lineales mediante divisiones sucesivas del espacio de datos.

Por su parte, la red neuronal MLP también utilizó las ocho variables predictoras y obtuvo el mejor desempeño de los tres modelos evaluados, con un MSE de 0,3017, un RMSE de 0,5493 y un R^2 de 0,7697. Dentro de esta ejecución, fue el modelo que presentó el menor error y la mayor capacidad explicativa sobre el conjunto de prueba. Estos resultados muestran que la red neuronal fue capaz de aprovechar de mejor manera la información contenida en las variables disponibles para generar predicciones más cercanas a los valores reales.

Al comparar los modelos, se observa una mejora progresiva desde la regresión lineal simple hacia el árbol de decisión y posteriormente hacia la red neuronal MLP. Sin embargo, esta comparación debe interpretarse considerando que la regresión lineal simple utiliza solamente MedInc, mientras que el árbol de decisión y la red neuronal utilizan las ocho variables predictoras. Por esta razón, las diferencias obtenidas no dependen únicamente del algoritmo, sino también de la cantidad de información utilizada por cada modelo.

En función de las métricas obtenidas, la Red Neuronal MLP se identifica como el modelo con mejor desempeño predictivo en esta fase. Aun así, los tres modelos aportan información útil al análisis, la regresión lineal simple entrega una referencia inicial e interpretable, el árbol de decisión mejora la capacidad de representar relaciones más complejas y la red neuronal alcanza el mejor resultado global. En conclusión, estos resultados permiten contar con una base sólida para la continuidad del proyecto.

XI. Uso de fuentes, citación y referencias

Las referencias utilizadas corresponden a los apuntes citados en el notebook y a fuentes incluidas en la guía del informe para respaldar las herramientas y conceptos aplicados.

- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer. <https://doi.org/10.1007/978-3-031-38747-0>
- Ruete, D. (2026a). *Evaluación de modelos de regresión* [Apunte]. Universidad Andrés Bello.
- Ruete, D. (2026b). *Modelos de aprendizaje supervisado - Regresión* [Apunte]. Universidad Andrés Bello.
- Ruete, D. (2026c). *Regresión con árboles de decisión* [Apunte]. Universidad Andrés Bello.
- Ruete, D. (2026d). *Regresión con redes neuronales artificiales* [Apunte]. Universidad Andrés Bello.
- Ruete, D. (2026e). *Regresión lineal simple, polinomial y multivariable* [Apunte]. Universidad Andrés Bello.
- scikit-learn Developers. (2026). *scikit-learn documentation*. <https://scikit-learn.org/stable/>

XII. Anexos

Anexo A. Evidencia resumida del código del notebook

```
SEMILLA = 42
np.random.seed(SEMILLA)
indices_train, indices_test = train_test_split(
    df.index, test_size=0.20, random_state=SEMILLA)

linear_model = LinearRegression()
decision_tree_model = DecisionTreeRegressor(max_depth=5, random_state=SEMILLA)
mlp_model = MLPRegressor(hidden_layer_sizes=(100,), activation="relu",
    solver="adam", max_iter=500, random_state=SEMILLA, early_stopping=True)
```

Anexo B. Resultados finales

Modelo	MSE	RMSE	R ²
Regresión Lineal Simple	0,7091	0,8421	0,4589
Árbol de Decisión	0,5245	0,7242	0,5997
Red Neuronal MLP	0,3017	0,5493	0,7697